

## DATACENTRIC AI (IMD3011)

Carga Horária: 04 Créditos (60 horas)

Semestre: 2025.1

Docente: Elias Jacob de Menezes Neto

Horários: 5N1234 (19:00 às 22:10, sala A303)

Quantidade de vagas: 30

### 1. Objetivo

- Introduzir os conceitos e fundamentos da Datacentric AI, enfatizando a importância da qualidade e curadoria dos datasets.
- Apresentar técnicas avançadas de aprendizado de máquina em cenários com disponibilidade limitada de dados anotados, incluindo métodos de supervisão fraca, semi-supervisionada e técnicas one-shot/few-shot.
- Propiciar experiências práticas com frameworks e ferramentas que integram funções de rotulagem, detecção automatizada de erros, explicabilidade de modelos e active learning, preparando os alunos para desafios reais de mercado e pesquisa.

### 2. Ementa

Métodos avançados de aprendizado de máquina em contextos de disponibilidade limitada de dados anotados. Curadoria e construção de datasets para tarefas supervisionadas. Aprendizado fracamente supervisionado: funções de rotulagem e modelos para desambiguação de rótulos conflitantes. Aprendizado semisupervisionado. Transfer learning no contexto de supervisão fraca. Obtenção de rótulos com técnicas one-shot e few-shot. Identificação automatizada de erros nos rótulos de datasets para tarefas supervisionadas. Técnicas de explicabilidade de modelos de IA para melhoria de datasets.

### 3. Metodologia

Oferecerei o curso no formato de ensino presencial. A rotina do curso é a seguinte: (1) a primeira atividade de cada aula consiste na realização da chamada, (2) seguida da revisão do conteúdo da aula anterior; (3) a etapa seguinte focará no conteúdo do dia.

Utilizarei um método de ensino *top-down*, que é diferente de como a maioria dos cursos funciona. Normalmente, em uma abordagem *bottom-up*, você primeiro aprende todos os componentes separados que irá utilizar e, em seguida, reúne-os gradualmente em estruturas mais complexas. Os problemas com isso é que os alunos frequentemente perdem a motivação, não têm uma visão do "quadro geral" e não sabem o que precisarão lá na frente. Sabe aquela sensação de "pra que danado eu vou usar isso?", pois então.

David Perkins, professor de educação da Universidade de Harvard, tem um livro chamado "[Making Learning Whole](#)", em que ele usa o jogo de beisebol como analogia (pense em futebol, dá no mesmo). Quando crianças estão aprendendo a jogar, não exigimos que elas memorizem todas as regras do jogo e entendam todos os detalhes técnicos antes de permitir que elas joguem. Ao contrário, elas começam a jogar com apenas uma noção geral e, gradualmente, aprendem mais regras/detalhes à medida que o tempo passa.

Tudo isso para dizer, não se preocupe se você não entender tudo no início. É esperado que você não entenda. Começaremos a usar algumas "caixas pretas" que ainda não foram explicadas, e então, iremos nos aprofundar nos detalhes delas mais tarde. **Concentre-se no que as coisas FAZEM, não no que elas SÃO.**

Você não vai aprender nada só assistindo a aula. As pessoas aprendem **fazendo** (construindo código) e **explicando** o que aprenderam (apresentando e ajudando os outros).

Na linha do David Perkins, utilizaremos cadernos Jupyter com código em python durante praticamente todas as aulas. Os cadernos são feitos de modo que você consiga estudar tudo depois com calma. Tudo fica mais fácil quando vira código.

Cadernos Jupyter utilizados: <https://jacob.al/IMD3011>

Fora da sala de aula, estarei à disposição para tirar dúvidas mediante agendamento via e-mail [elias.jacob@ufrn.br](mailto:elias.jacob@ufrn.br). Caso você tenha críticas, elogios ou comentários que deseje expressar de forma anônima, você pode usar o seguinte formulário do Google Forms <https://jacob.al/feedbacks>

#### 4. Procedimentos de avaliação da aprendizagem

Considero a avaliação da aprendizagem como um processo dinâmico que abarca aquisição de conteúdos, habilidades e desenvolvimento de atitudes. Durante o curso, os alunos(as) serão avaliados individualmente e em grupo. As avaliações individuais serão fruto da participação em encontros e prova escrita. No caso de avaliação em grupo, serão realizadas duas atividades para discussão de conteúdos adicionais e implementação de soluções. A ideia é trabalhar pontos além daqueles vistos no semestre, com uma ideia de *Bring Your Own Data*, isto é, com datasets diferentes daqueles utilizados em sala de aula.

A nota ao final do curso será a média aritmética das notas obtidas durante cada unidade (10,0). As atividades avaliativas de unidades encontram-se descritas no quadro da agenda do curso.

#### 5. Cronograma e critérios para a realização das atividades e validação da assiduidade dos discentes

Apresento o cronograma com os critérios para a realização das atividades ao final deste documento. A assiduidade dos estudantes é avaliada pela presença nos encontros síncronos. Para ser aprovado, o estudante deve obter 75% de presença e média parcial igual ou superior a 7,0 (sete) ou média parcial igual ou superior a 6,0 (seis), com rendimento acadêmico igual ou superior a 4,0 (quatro) em todas as unidades.

#### 6. FAQ

- Eu vou precisar faltar em razão de {doença do cachorro, doença própria, guerra nuclear etc.}. Preciso avisar? **Não**
- Se eu chegar depois da chamada, vou levar falta? **Sim (casos excepcionais serão tratados excepcionalmente)**
- Quantas vezes eu posso faltar? **Quantas o SIGAA disser que pode.**
- Posso ter a minha falta abonada? **Não existe abono de faltas.**
- As provas têm consulta? **Não.**

## 7. Agenda do curso

Semana	Data	Aula	Atividades pontuadas
<b>Unidade 1</b>			
<b><i>Fundamentos de Aprendizado Fracamente Supervisionado</i></b>			
1	20/03	Apresentação da disciplina e introdução ao tema de Datacentric AI	-
2	27/03	Aprendizado Semi-Supervisionado e Calibragem de Modelos de Aprendizado de Máquina	-
3	03/04	Positive Unlabeled Learning	-
4	10/04	Pipeline Básica de Aprendizado Fracamente Supervisionado – Parte 1 (funções de rotulagem)	-
5	24/04	Pipeline Básica de Aprendizado Fracamente Supervisionado – Parte 2 (modelos de rotulagem)	-
6	08/05	Atividade avaliativa 1 – <i>Bring your own data</i> – Apresentação de projeto com AFS – envio no SIGAA)	10,00
<b>Unidade 2</b>			
<b><i>Técnicas Avançadas de Detecção de Ruídos e Supervisão Fraca</i></b>			
6	08/05	Detecção de Erros de Anotação	
7	15/05	Confident Learning 1	-
8	22/05	Confident Learning 2	-
9	29/05	Supervisão Fraca para Reconhecimento de Entidades Nomeadas	-
10	05/06	Modelos de Rotulagem Avançados	-
11	12/06	Atividade avaliativa 2 – <i>Bring your own data</i> – Apresentação de projeto – envio no SIGAA)	10,00
<b>Unidade 3</b>			
<b><i>Interatividade, Explicabilidade e Grandes Modelos de Linguagem</i></b>			
11	12/06	Funções de influência	
12	26/06	Active Learning	-
13	03/07	Uso de Grandes Modelos de Linguagem para Anotação Zero/Few-Shot	
14	10/07	Explicabilidade de Modelos de Aprendizado de Máquina	-
15	17/07	Prova	10,00
<b>Nota final: média das três unidades</b>			
16	24/07	Reposição	10,00

## 8. Referências básicas

CHEN, M. F. et al. **Shoring Up the Foundations: Fusing Model Embeddings and Weak Supervision**. , 1 ago. 2022. Disponível em: <<http://arxiv.org/abs/2203.13270>>.

GOH, H. W.; TKACHENKO, U.; MUELLER, J. **CROWDLAB: Supervised learning to infer consensus labels and quality scores for data with multiple annotators**. arXiv, , 27 jan. 2023. Disponível em: <<http://arxiv.org/abs/2210.06812>>.

KLIE, J.-C.; WEBBER, B.; GUREVYCH, I. **Annotation Error Detection: Analyzing the Past and Present for a More Coherent Future**. arXiv, , 25 set. 2022. Disponível em: <<http://arxiv.org/abs/2206.02280>>.

LISON, P.; BARNES, J.; HUBIN, A. **skweak: Weak Supervision Made Easy for NLP**. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations. **Anais...**2021. Disponível em: <<http://arxiv.org/abs/2104.09683>>.

NORTHCUTT, C. G.; JIANG, L.; CHUANG, I. L. **Confident Learning: Estimating Uncertainty in Dataset Labels**. arXiv, , 21 ago. 2022. Disponível em: <<http://arxiv.org/abs/1911.00068>>.

RATNER, A. et al. **Data Programming: Creating Large Training Sets, Quickly**. arXiv, , 8 jan. 2017. Disponível em: <<http://arxiv.org/abs/1605.07723>>.

ZHANG, J. et al. **Understanding Programmatic Weak Supervision via Source-aware Influence Function**. (S. Koyejo et al., Eds.)Advances in Neural Information Processing Systems. **Anais...**Curran Associates, Inc., 2022. Disponível em: <[https://proceedings.neurips.cc/paper\\_files/paper/2022/file/1343edb2739a61a6e20bd8764e814b50-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2022/file/1343edb2739a61a6e20bd8764e814b50-Paper-Conference.pdf)>

ZHOU, Z.-H. **A brief introduction to weakly supervised learning**. National Science Review, v. 5, n. 1, p. 44–53, 1 jan. 2018.

## 9. Referências complementares

FRENAY, B.; VERLEYSEN, M. **Classification in the Presence of Label Noise: A Survey**. IEEE Transactions on Neural Networks and Learning Systems, v. 25, n. 5, p. 845–869, maio 2014.

HAMMOUDEH, Z.; LOWD, D. **Training Data Influence Analysis and Estimation: A Survey**. Disponível em: <<https://arxiv.org/abs/2212.04612v2>>.

NODET, P. et al. **From Weakly Supervised Learning to Biquality Learning: an Introduction**. 2021 International Joint Conference on Neural Networks (IJCNN). **Anais...** Em: 2021 INTERNATIONAL JOINT CONFERENCE ON NEURAL NETWORKS (IJCNN). Shenzhen, China: IEEE, 18 jul. 2021. Disponível em: <<https://ieeexplore.ieee.org/document/9533353/>>.

NORTHCUTT, C. G.; ATHALYE, A.; MUELLER, J. **Pervasive Label Errors in Test Sets Destabilize Machine Learning Benchmarks**. arXiv, , 7 nov. 2021. Disponível em: <<http://arxiv.org/abs/2103.14749>>. Acesso em: 10 jan. 2023  
PUKDEE, R. et al. **Label Propagation with Weak Supervision**. arXiv, , 9 abr. 2023. Disponível em: <<http://arxiv.org/abs/2210.03594>>.

RATNER, A. et al. Snorkel: Rapid Training Data Creation with Weak Supervision. **Proceedings of the VLDB Endowment**, v. 11, n. 3, p. 269–282, nov. 2017.

VARMA, P. et al. **Learning Dependency Structures for Weak Supervision Models**. arXiv, , 14 mar. 2019. Disponível em: <<http://arxiv.org/abs/1903.05844>>.

ZHANG, J. et al. **WRENCH: A Comprehensive Benchmark for Weak Supervision**. arXiv, , 11 out. 2021. Disponível em: <<http://arxiv.org/abs/2109.11377>>.

ZHANG, J.; SONG, L.; RATNER, A. **Leveraging Instance Features for Label Aggregation in Programmatic Weak Supervision**. arXiv, , 9 out. 2022. Disponível em: <<http://arxiv.org/abs/2210.02724>>.